

# INT8 추론에서 모의 양자화와 정수 실행 간 격차의 연산자별 기여도 분석

[저자 성명]

**Abstract**—INT8 배포 판단은 시뮬레이터 위에서 내려진다. 부동소수점 그래프에 양자화-역양자화(“모의 양자화”) 노드를 끼워 넣어 돌리고, 그 정확도를 정수 타겟의 정확도로 대신 읽는다. 이 논문은 그 대신 읽기가 어디까지 성립하는지를 정확도와 텐서에 대해 따로 측정한다. 기준은 **TensorFlow Lite** 참조 커널과 비트 단위로 일치하는 정수 엔진이다. 신경망 6종, 양자화 방식 2종, 전체 테스트셋에서 정확도는 성립한다. 모의 대 정수 차이는 모두 0.20 %p 이내이고 12개 95% 신뢰구간이 전부 0을 포함한다. 텐서는 성립하지 않는다. 출력 코드의 28.5–72.7%가 다르고, 이미지의 95–100%에서 코드가 최소 하나 다르다. 교사 강제로 분해하면 격차의 출처가 연산자별로 드러난다. 합성곱·선형·풀링은 각각 자기 코드의 1% 미만에서만 어긋나지만 정수 **LayerNorm**은 24.8%에서 어긋난다. 시뮬레이터의 **LayerNorm**을 정수에 충실하게 바꾸면 이 원천은 통제로 사라지지만(24.77% → 0.00%) 전파된 출력 불일치는 72.7%에서 65.7%로만 내려간다. 시뮬레이터를 연산자 하나씩 고쳐서 비트 정확한 벡터의 공급원으로 만들 수는 없다는 뜻이다. 아울러 정확도 대리지표가 값을 매기지 못하는 재양자화 선택 하나를 측정한다. 반올림을 절사로 바꾸면 18개 (모델, 시드, 방식) 조합 전부에서 0.90–3.37 %p를 잃으며, 그 손해의 부호는 시드를 넘어 옮겨 가지만 크기는 옮겨 가지 않는다.

**Index Terms**—양자화, 정수 연산, 임베디드 추론, 신경망 처리 장치, 재현성.

## 1. 서론

INT8 배포는 서로 다른 두 프로그램이 결정한다. 질문에 답하는 쪽은 양자화-역양자화(“모의 양자화”) 노드가 삽입된 부동소수점 그래프이고, 그 정확도가 곧 양자화 정확도로 보고된다 [1], [2]. 실제로 출하되는 쪽은 정수 프로그램이다. int8 가중치, int32 누산기, 고정소수점 곱셈-시프트 재양자화로 이루어진다 [3]. 현업은 돌을 바꿔 써도 되는 것으로 다루고, 정확도에 관한 한 대체로 그렇다 [4].

그러나 시뮬레이터에 요구되는 것이 정확도뿐인 것은 아니다. 실리콘 브링업과 컴파일러 검증에는 골든 벡터, 곧 장치가 내놓아야 할 정수 텐서 그 자체가 필요하다. 학습 후 양자화 회귀를 추적하려면 어느 연산자에서 격차가 시작되었는지를 알아야 한다. 둘 다 텐서에 관한 질문이고, 저자가 아는 한 어느 쪽도 측정된 바 없다. 이 논문은 세 가지를 묻는다. **RQ1**: 정확도가 일치하면 텐서도 일치하는가? **RQ2**: 격차를 만드는 연산자는 무엇이며, 가장 큰 것을 없애면 격차가 닫히는가? **RQ3**: 정확도 대리지표는 무엇에 값을 매기지 못하는가?

이 질문들에 답하려면 기존 계층별 오차 분석이 제공하지 않는 분해가 필요하다. 연산자 자신의 정수 연산이 만드는 뭉(국소 불일치, 교사 강제로 분리)과 종단간 실행에서 살아남는 뭉(전파 불일치)을 갈라내는 분해다. 전체 테스트셋에서 대응 표준오차와 함께 보고하는 이 분해가 이 논문의 방법론적 기여이고, 발견 1–5가 실험적 기여다.

저자는 무소속 연구자이다. [도시], 대한민국. e-mail: ykh13571@gmail.com

표와 그림을 재현하는 데 필요한 코드·체크포인트·결과 파일 전부: <https://github.com/sokldjs554/npuloop>.

## 2. 배경 및 관련 연구

모의 양자화 그래프는 텐서를 양자화 격자에 맞춰 반올림하고 자른 뒤 다시 부동소수점으로 돌아오므로, 모든 연산자가 여전히 float32로 돈다. 정수 프로그램은 대신 int8 코드를 끝까지 유지하고 Q31 승수와 시프트로 다시 스케일한다 [1], [3]. 따라서 두 프로그램은 의도에서는 일치하고 최하위 비트마다 어긋날 자유를 갖는다.

MQBench [5]는 학술 양자화와 배포 가능한 백엔드 사이의 격차를 측정하되 그것을 정확도로 보고한다. 양자화 백서들 [4], [2]은 모의 양자화를 정수 파이프라인의 시뮬레이션으로 다룬다. 배포 툴체인이 계층별 오차 분석은 양자화된 계층이 부동소수점 대응물에서 얼마나 떨어져 있는지를 잴다. 이 논문의 측정은 종류가 다르다. 시뮬레이터가 장치에서 실제로 일어나는 정수 실행에서 얼마나 떨어져 있는지를, 신호 대 잡음비가 아니라 코드 단위로 잴다. 정수만 쓰는 트랜스포머 추론은 정수 **LayerNorm**과 소프트맥스 커널을 이미 확립했다 [6], [7]. 그 연산자에 대한 기여는 커널이 아니라 커널과 시뮬레이터가 어긋나는 크기이고, 그것을 고치는 것만으로는 충분하지 않다는 증거다. 누산기 폭은 학습 시 제약으로 연구되어 왔다 [8]. 여기서 재는 측은 그 대신 재양자화 단계의 반올림, 즉 순수한 구현 선택이다.

## 3. 측정 방법

### 3.1 정수 엔진과 외부 검증

보정을 마친 모의 양자화 그래프를 정수 그래프로 내보낸다. int8 가중치, int32 편향, 출력 채널별 Q31 승수와 시프트로 이루어진다. 실행은 `MultiplyByQuantizedMultiplier`의 `gemmlowp/TensorFlow Lite` 의미론을 따르며 [3], 포화 반올림 배중 상위곱과 2의 거듭제곱 반올림 나눗셈을 포함한다. 서로 독립인 두 구현(NumPy와 C++)이 모든 중간 텐서에서 일치해야 하고, 파이썬을 쓰지 않는 세 번째 C++ 실행기가 직렬화된 파일로부터 같은 코드를 재현한다.

엔진은 자기 자신이 아니라 외부 오라클에 대해 검증한다. TensorFlow Lite 완전 정수 모델의 스케일·영점·가중치·편향으로 정수 그래프를 세우면, 합성곱과 풀링이 기존 방식의 이중 반올림을 쓰고 완전 연결 계층이 단일 반올림을 쓸 때 1000/1000 이미지의 모든 텐서에서 일치한다. 이 기준이 얼마나 뻘뻘한지에 대한 눈금으로, 같은 모델에서 TensorFlow Lite 자신의 최적화 델리게이트와 참조 커널은 1000장 중 155장에서 서로 다른 답을 낸다.

### 3.2 국소 불일치와 전파 불일치

한 장의 이미지에 대해, 모의 양자화 그래프가 노드  $n$ 에서 만드는 코드를  $f_n$ (양자화기 출력을 정수 코드로 환산한 것), 정수 엔진을 종단간으로 돌렸을 때 같은 노드에서 나오는 코

표 I

모의 양자화 대 비트 단위로 일치하는 정수 실행, 전체 테스트셋, PC는 채널별 가중치, PT는 텐서별 가중치,  $\Delta$ 는 같은 이미지에서 랜 (정수 - 모의) top-1이며 대응 표준오차를 함께 적었다. “코드”는 서로 다른 출력 로짓 코드의 비율, “이미지”는 코드가 하나라도 다른 이미지의 비율이다.

| 신경망                    | 방식 | float32 | 모의    | 정수    | $\Delta$ (%p)    | 95% CI           | 일치(%) | 코드(%) | 이미지(%) |
|------------------------|----|---------|-------|-------|------------------|------------------|-------|-------|--------|
| ResNet-20 ReLU         | PC | 89.59   | 89.54 | 89.55 | $+0.01 \pm 0.08$ | $[-0.14, +0.16]$ | 99.37 | 50.1  | 99     |
| ResNet-20 ReLU         | PT | 89.59   | 89.61 | 89.67 | $+0.06 \pm 0.08$ | $[-0.11, +0.23]$ | 99.18 | 51.7  | 99     |
| ResNet-20 SiLU         | PC | 90.34   | 90.35 | 90.26 | $-0.09 \pm 0.09$ | $[-0.26, +0.08]$ | 99.06 | 61.6  | 100    |
| ResNet-20 SiLU         | PT | 90.34   | 90.17 | 90.26 | $+0.09 \pm 0.09$ | $[-0.08, +0.26]$ | 99.07 | 62.9  | 100    |
| MobileNetV2-0.5        | PC | 90.23   | 90.30 | 90.29 | $-0.01 \pm 0.08$ | $[-0.16, +0.14]$ | 99.28 | 50.4  | 100    |
| MobileNetV2-0.5        | PT | 90.23   | 90.23 | 90.27 | $+0.04 \pm 0.07$ | $[-0.10, +0.18]$ | 99.37 | 51.4  | 100    |
| ViT-128/6              | PC | 80.98   | 80.87 | 80.97 | $+0.10 \pm 0.13$ | $[-0.15, +0.35]$ | 97.93 | 72.7  | 100    |
| ViT-128/6              | PT | 80.98   | 80.77 | 80.97 | $+0.20 \pm 0.12$ | $[-0.04, +0.44]$ | 98.07 | 72.6  | 100    |
| Inception-32           | PC | 89.59   | 89.55 | 89.56 | $+0.01 \pm 0.05$ | $[-0.09, +0.11]$ | 99.69 | 28.5  | 95     |
| Inception-32           | PT | 89.59   | 89.52 | 89.47 | $-0.05 \pm 0.06$ | $[-0.17, +0.07]$ | 99.52 | 31.1  | 96     |
| ResNet-20 (Imagenette) | PC | 83.97   | 84.05 | 83.97 | $-0.08 \pm 0.10$ | $[-0.27, +0.12]$ | 99.52 | 35.7  | 95     |
| ResNet-20 (Imagenette) | PT | 83.97   | 84.00 | 84.05 | $+0.05 \pm 0.11$ | $[-0.17, +0.27]$ | 99.31 | 36.2  | 96     |

드를  $i_n$ 이라 하자. 노드  $n$ 의 전파 불일치는  $f_n \neq i_n$ 인 원소의 비율이다. 국소 불일치는 노드  $n$ 의 정수 커널에 입력으로 모의 양자화 코드를 먹이고(교사 강제) 그 노드의 출력만 비교한 것이다. 국소 불일치는 한 연산자의 정수 연산이 만드는 뭉을 떼어 내고, 전파 불일치는 그 뭉이 얼마나 멀리 가는지 보여 준다.

### 3.3 통계, 모델, 양자화 방식

정확도 차이는 대응 표본으로 다룬다. 같은 이미지를 세 번(부동소수점, 모의 양자화, 정수) 평가하고, 이미지별 정답 여부 차이의 평균을 표준오차  $s/\sqrt{n}$  및 95% Wald 구간과 함께 보고한다. 정확도 열은 전체 테스트셋을 쓴다(CIFAR-10 10,000장, Imagenette 3,925장). 노드별 분해는 고정된 250장 배치(Imagenette는 125장)를 쓴다.

CIFAR-10 신경망 5종 — ReLU를 쓰는 ResNet-20과 SiLU를 쓰는 ResNet-20, MobileNetV2-0.5(깊이별 합성곱), 분기를 연결하는 Inception 계열 CNN, ViT-128/6(어텐션 블록 12개, LayerNorm 13개) — 과 Imagenette를  $128 \times 128$ 로 학습한 ResNet-20 1종을 쓴다. 학습 후 양자화 방식은 둘이다. 채널별 가중치에 비대칭 활성화를 쓰는 방식(PC)과 텐서별 가중치를 쓰는 방식(PT)이며, 둘 다 학습 이미지 512장으로 보정했다. 학습과 평가는 모두 CPU에서 수행했고, 아래의 모든 수치는 저장소에 커밋된 결과 파일에서 스크립트가 만들어 낸다.

## 4. 실험 결과

### 4.1 RQ1: 정확도는 일치하고 텐서는 일치하지 않는다

표 I이 핵심 측정이다. 모의 대 정수 정확도 차이의 최댓값은 0.20 %p,  $|\Delta|/SE$ 의 최댓값은 1.6이며, 12개 신뢰구간이 모두 0을 포함한다. 이 표본 크기에서 정확도 대리치표는 정확한 것과 구별되지 않고, 이미지 단위 top-1 일치율은 97.9–99.7%다. 같은 행이 텐서에서는 어긋난다. 출력 로짓 코드의 28.5%(Inception-32)에서 72.7%(ViT-128/6)가 다르고, 이미지의 95–100%에서 코드가 최소 하나 다르다. 트랜스포머가 극단이기는 하나 예외는 아니다. CNN들이 50–63%, 입력이 더 큰 Imagenette 모델이 36%에 자리한다.

**발견 1.** 정확도 일치와 텐서 일치는 두 자릿수 이상 분리되어 있으며, 모든 신경망과 두 방식 모두에서 그렇다.

실무 함의. 정확도가 99% 일치한다는 보고는 시뮬레이터가 검증 벡터를 공급할 수 있다는 증거가 되지 못한다.




그림 1. 노드별 코드 불일치, PC 방식. 국소(교사 강제) 불일치는 LayerNorm을 뺀 모든 연산자에서 1% 미만이고, 전파 불일치는 첫 합성곱에서 시작해 출력의 50–73%까지 올라간다. 세로축은 로그 눈금이며, 국소 불일치가 0인 노드(로컬 테이블 활성화, 잔차 덧셈)는 그리지 않았다.

### 4.2 RQ2: 격차는 어디서 태어나는가

그림 1이 두 성분을 갈라 놓는다. 국소 불일치는 작고 평평하다. 합성곱은 자기 코드의 0.02–0.93%, 선형 계층은 0.03–0.96%, 평균 풀링은 0.1–2.7%(반올림 동점)에서 어긋나며, int8 로컬 테이블 활성화는 정확히 0%다. 이들은 모두 최하위 비트  $\pm 1$  수준의 차이이다. 반면 전파 불일치는 첫 합성곱에서부터 — 12개 행 전부에서 첫 격차가 그 노드다 — 단조롭게 올라가 출력에서 28–73%에 이른다.

작지 않은 연산자가 하나 있다. 정수 LayerNorm은 부동소수점 대응물과 자기 코드의 24.8%에서 어긋나며, 13개 인스턴스 중 최댓값은 26.2%다. 정수 구현은 int64 합과 정확한 정수 제공근으로 정규화하는 반면 시뮬레이터는 float32로 계산한 뒤 격자에 스냅하므로, 대략 원소 넷 중 하나가 반올림 경계의 반대편에 떨어진다.

**발견 2.** LayerNorm을 빼면 어떤 연산자도 자기 코드의 1% 미만에서만 어긋나고, 그 어긋남은 모두 최하위 비트  $\pm 1$ 이다. 종단간 격차는 특정 커널이 만든 것이 아니라 전파가 키운 것이다.

**발견 3.** 정수 LayerNorm은 유일하게 큰 국소 원천으로, 다른

표 II

시뮬레이터의 **LAYERNorm**을 정수에 충실하게 바꾼 결과(ViT-128/6, 10,000장). 각 방식의 두 행 사이에서 정수 프로그램은 바뀌지 않았고 시뮬레이터의 **LAYERNorm**만 다르다. 로짓 절대차 평균은 PC에서 0.119 → 0.091, PT에서 0.118 → 0.093으로 줄어든다.

| 방식 | LayerNorm | 국소(%) | 코드(%) | 일치(%) | $\Delta$ (%p) |
|----|-----------|-------|-------|-------|---------------|
| PC | float32   | 24.77 | 72.7  | 97.93 | +0.10 ± 0.13  |
| PC | 정수 (13개)  | 0.00  | 65.7  | 98.29 | +0.25 ± 0.11  |
| PT | float32   | 24.76 | 72.6  | 98.07 | +0.20 ± 0.12  |
| PT | 정수 (13개)  | 0.00  | 66.0  | 98.60 | +0.13 ± 0.10  |




그림 2. 기준 재양자화 반올림 대비 top-1 변화, 전체 테스트셋, 신경망당 독립적으로 학습한 체크포인트 3개(오차 막대는 대응 표준오차). 편향된 방식들은 모든 조합에서 손해를 보지만, 얼마나 손해인지는 시드마다 다르다.

모든 연산자보다 두 자릿수 크다.

**실무 함의.** 트랜스포머를 INT8로 옮길 때는 **LayerNorm**을 가장 먼저 의심하고, 나머지에서는  $\pm 1$  LSB를 예상하라.

#### 4.3 RQ2: 가장 큰 국소 원천을 제거하면

격차가 연산자별 오차의 합이라면 가장 큰 항을 없앴을 때 그만큼 줄어야 한다. 이를 직접 시험한다. 시뮬레이터의 **LayerNorm**을, 입력 코드 위에서 엔진의 연산을 그대로 수행하여 구성적으로 비트 단위까지 같은 모듈로 교체하되, 내보낸 정수 프로그램은 그대로 둔다(실험이 이 사실을 단언한다).

표 II이 그 결과다. **LayerNorm**의 국소 불일치는 24.77%에서 정확히 0.00%로 내려가고 로짓 절대차 평균은 약 23% 개선된다. 그러나 전파된 출력 코드 불일치는 72.7%에서 65.7%로만 움직인다(텐서별은 72.6% → 66.0%). 정확도는 어느 방향으로든 대응 표준오차 두 배 안쪽에서 움직이므로 개선으로 읽을 수 없다.

**발견 4.** 가장 큰 국소 원천 하나를 완전히 없애도 전파 격차의 10분의 1 정도만 회수된다. 남은 것이 개별적으로는 코드의 1% 미만에서만 어긋나는 연산자들의  $\pm 1$  LSB 사건이 증폭된 결과이기 때문이다.

**실무 함의.** 골든 벡터는 외부 기준에 대해 검증된 정수 구현에서 나와야 한다. 부동소수점 시뮬레이터를 연산자 하나씩 고쳐 나가는 길은 대체제가 되기에 너무 느리게 수렴한다.

#### 4.4 RQ3: 정확도 대리지표가 가리는 비용

재양자화의 곱셈-시프트는 반올림 단계로 끝나는데, 구현에 따라 이를 단순 산술 시프트로 바꾸고 싶은 유혹이 있다. 그림 2과 표 III은 그 선택을 기준 구현과 비교해 전체 테스트셋에서, 신경망당 독립적으로 학습한 체크포인트 3개로 측정하는 것이다.

표 III

기준 구현 대비 반올림 방식의 손해, 시드 3개의 평균 ± 표준편차(%p).

| 반올림       | ResNet-20 ReLU | ResNet-20 SiLU | MobileNetV2-0.5 |
|-----------|----------------|----------------|-----------------|
| single    | -0.03 ± 0.09   | +0.01 ± 0.02   | -0.00 ± 0.13    |
| half_even | -0.07 ± 0.09   | +0.02 ± 0.09   | +0.00 ± 0.09    |
| truncate  | -0.98 ± 0.12   | -2.31 ± 0.85   | -2.12 ± 0.21    |
| floor     | -1.42 ± 0.06   | -2.42 ± 1.04   | -1.43 ± 0.40    |

**truncate**와 **floor**는 18개 (모델, 시드, 방식) 조합 전부에서 기준보다 나빴고, 그 폭은 0.90–3.37 %p,  $|\Delta|/SE$ 는 4.4에서 11.8 사이였다. 반면 단일 반올림과 짝수 반올림 경로는 잡음 범위를 벗어나지 않는다( $|\Delta| \leq 0.13$  %p). 크기는 옮겨가지 않는다. **ResNet-20 SiLU**에서 **truncate**의 손해는 시드 3개에 걸쳐 1.36에서 2.98 %p까지 벌어져 시드 표준편차가 효과 크기의 37%에 이르는 반면, **ResNet-20 ReLU**는 효과의 10분의 1 이내에 머문다. 두 편향 방식 중 어느 쪽이 더 나쁜지는 연산의 성질이 아니라 신경망의 성질이다. **ResNet-20 ReLU**는 세 시드 모두에서 **floor**가, **MobileNetV2**는 세 시드 모두에서 **truncate**가 더 많이 잃는다.

**발견 5.** 반올림 방식 비용의 부호와 유의성은 시드에 강건하지만 크기는 그렇지 않다. 같은 구조의 시드 3개에서 효과 크기의 37%까지 벌어진다.

**실무 함의.** 반올림 방식의 비용을 시드 하나의 수치로 인용해서는 안 된다.

### 5. 타당성 위협

**외적 타당성.** 신경망은 CIFAR-10 규모에  $128 \times 128$  ImageNet 모델 하나를 더한 것이고, 여섯 모델 모두 분류기다. 따라서 결론은 격차의 구조에 관한 것이지 ImageNet 규모 그 래프에서의 정확한 크기에 관한 것이 아니다. 출력 텐서 자체가 결과물인 밀집 출력 과제 — 초해상, 분할, 검출 — 라면 여기서 정확도가 가린 텐서 격차가 더 직접 드러날 것이다.

**구성 타당성.** 국소 불일치는 교사 강제로 재드로 연산자의 연산만 떼어 보고 상류 오차와의 상호작용은 보지 않는다. 그 상호작용을 담는 것은 전파 열이다.

**결론 타당성.** 표 I의 정확도 비교 12개와 표 II의 4개는 다중 비교 보정을 하지 않았다(16개 전체에서  $|\Delta|/SE$ 의 최댓값은 2.2). 시드 3개는 반올림 측만 덮고, 나머지 측정은 신경망당 체크포인트 하나를 쓴다.

**내적 타당성.** 외부 비트 일치 검증은 합성곱·풀링·완전 연결 계층을 덮고, 깊이별 합성곱·원소별 덧셈·소프트맥스는 덮지 않는다.

### 6. 재현 자료

모든 수치는 커밋된 결과 파일에서 스크립트가 출력하며, 스크립트와 학습된 체크포인트와 그 결과 파일은 모두 공개되어 있다. `make_tables.py`가 표 I–III을, `make_figs.py`가 그림 1–2을 다시 만든다. 지속적 통합 작업이 커밋마다 생성기를 다시 돌려, 커밋된 표가 결과 파일이 함의하는 표와 다르면 실패시킨다. 측정 자체는 `e15_fidelity.py` (표 I, 그림 1), `e16_ln_emulation.py` (표 II), `e14_rounding_seeds.py` (그림 2, 표 III)에 있고, 외부 검증은 `e11_tflite_crosscheck.py`다. 시드를 쓴 측정에는 단서가 하나 붙는다. 이 체크포인트들을 만들 당시 학습기의 시드는 데이터 순서만 통제하고 가중치

초기화는 통제하지 못했으므로, 세 반복은 서로 독립인 표본이지만 같은 명령으로 비트 단위까지 재현되지는 않는다.

## 7. 결론

모의 양자화는 INT8 정확도는 잘 맞히고 INT8 텐서는 잘 못 맞히며, 두 사실은 서로 독립이다. 격차를 옮기는 연산자는 하나가 아니다. 개별적으로는 코드의 1% 미만에서만 어긋나는 연산자들에서 최하위 비트  $\pm 1$  사건으로 태어나 전파로 자라며, 그래서 가장 나쁜 국소 원천을 없애도 10분의 1밖에 회수되지 않는다. 골든 벡터가 필요한 팀은 외부 기준에 대해 검증된 정수 구현에서 그것을 만들어야 하고, 재양자화의 세 부를 바꾸는 팀은 여러 시드에서 측정해야 한다. 그 효과의 크기는 — 부호와 달리 — 옮겨 가지 않기 때문이다.

## 감사의 글

저자는 이 원고의 준비 과정에서 AI 코딩 도구(Claude Code)를 사용했으며, 모든 내용에 대한 책임은 저자에게 있다.

## 참고문헌

- [1] B. Jacob *et al.*, “Quantization and training of neural networks for efficient integer-arithmetic-only inference,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 2704–2713.
- [2] R. Krishnamoorthi, “Quantizing deep convolutional networks for efficient inference: A whitepaper,” *arXiv:1806.08342*, 2018.

- [3] B. Jacob *et al.*, “gemmlowp: a small self-contained low-precision GEMM library,” 2017. [Online]. Available: <https://github.com/google/gemmlowp>
- [4] M. Nagel *et al.*, “A white paper on neural network quantization,” *arXiv:2106.08295*, 2021.
- [5] Y. Li *et al.*, “MQBench: Towards reproducible and deployable model quantization benchmark,” in *Proc. NeurIPS Datasets and Benchmarks Track*, 2021.
- [6] S. Kim *et al.*, “I-BERT: Integer-only BERT quantization,” in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2021, pp. 5506–5518.
- [7] Y. Lin *et al.*, “FQ-ViT: Post-training quantization for fully quantized vision transformer,” in *Proc. Int. Joint Conf. Artif. Intell. (IJCAI)*, 2022, pp. 1173–1179.
- [8] I. Colbert *et al.*, “A2Q: Accumulator-aware quantization with guaranteed overflow avoidance,” in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2023, pp. 16989–16998.

## ENGLISH ABSTRACT

### Per-Operator Attribution of the Fake-Quantization-to-Integer Gap in INT8 Inference

INT8 deployment decisions are made on a simulator: the network runs in floating point with quantize–dequantize (“fake-quantization”) nodes inserted, and its accuracy stands in for the accuracy of the integer target. We measure how far that stand-in holds, for accuracy and for tensors separately, against an integer engine that is bit-exact with the TensorFlow Lite reference kernels. On six networks, two quantization schemes and complete test splits, it holds for accuracy: every fake-versus-integer difference is within 0.20 pp and all twelve 95% confidence intervals contain zero. It fails for tensors: 28.5–72.7% of the output codes differ, on 95–100% of the images. Teacher forcing attributes the divergence per operator: convolution, linear and pooling each disagree on under 1% of their own codes, while integer LayerNorm disagrees on 24.8%. Making the simulator integer-faithful at LayerNorm removes that source entirely (24.77%  $\rightarrow$  0.00%) but moves the propagated output mismatch only from 72.7% to 65.7%. We also price a requantization choice the accuracy proxy cannot see: replacing rounding with truncation costs 0.90–3.37 pp in all 18 (model, seed, mode) combinations, and the sign of that cost transfers across seeds while its magnitude does not.

**Index Terms**—Quantization, integer arithmetic, embedded inference, neural processing units, reproducibility.