

INT8 추론에서 모의 양자화와 정수 실행 간 격차의 연산자별 기여도 분석

[저자 성명]

Abstract—INT8 배포 판단은 시뮬레이터 위에서 내려진다. 부동소수점 그래프에 양자화-역양자화(“모의 양자화”) 노드를 끼워 넣어 돌리고, 그 정확도를 정수 타겟의 정확도로 대신 읽는다. 이 논문은 그 대신 읽기가 어디까지 성립하는지를 정확도와 텐서에 대해 따로 측정한다. 기준은 TensorFlow Lite 참조 커널과 비트 단위로 일치하는 정수 엔진이다. 신경망 6종, 양자화 방식 2종, 전체 테스트셋에서 정확도는 성립한다. 모의 대 정수 차이는 모두 0.20 %p 이내이고 12개 95% 신뢰구간이 전부 0을 포함한다. 텐서는 성립하지 않는다. 출력 코드의 28.5–72.7%가 다르고, 이미지의 95–100%에서 코드가 최소 하나 다르다. 교사 강제로 분해하면 격차의 출처가 연산자별로 드러난다. 합성곱·선형·풀링은 각각 자기 코드의 1% 미만에서만 어긋나지만 정수 LayerNorm은 24.8%에서 어긋난다. 시뮬레이터의 LayerNorm을 정수에 충실하게 바꾸면 이 원천은 통째로 사라지지만(24.77% → 0.00%) 전파된 출력 불일치는 72.7%에서 65.7%로만 내려간다. 시뮬레이터를 연산자 하나씩 고쳐서 비트 정확한 벡터의 공급원으로 만들 수는 없다는 뜻이다. 아울러 정확도 대리지표가 값을 매기지 못하는 재양자화 선택 하나를 측정한다. 반올림을 절사로 바꾸면 18개 (모델, 시드, 방식) 조합 전부에서 0.90–3.37 %p를 잃으며, 그 손해의 부호는 시드를 넘어 옮겨 가지만 크기는 옮겨 가지 않는다. argmax를 끌어내도 이 분리는 그대로다. 출력 텐서 자체가 결과물인 신경망에서 품질 지표는 6×10^{-4} dB 안쪽으로 충실한 반면 내보내는 픽셀 코드의 6.3%가 다르며, 폭을 고정한 채 연산자 수를 세 배로 늘리면 그 비율은 69.2%까지 오르는데도 품질 지표는 여전히 충실하다.

Index Terms—양자화, 정수 연산, 임베디드 추론, 신경망 처리 장치, 재현성.

1. 서론

INT8 배포는 서로 다른 두 프로그램이 결정한다. 질문에 답하는 쪽은 양자화-역양자화(“모의 양자화”) 노드가 삽입된 부동소수점 그래프이고, 그 정확도가 곧 양자화 정확도로 보고된다 [1], [2]. 실제로 출하되는 쪽은 정수 프로그램이다. int8 가중치, int32 누산기, 고정소수점 곱셈-시프트 재양자화로 이루어진다 [3]. 현업은 둘을 바꿔 써도 되는 것으로 다루고, 정확도에 관한 한 대체로 그렇다 [4].

그러나 시뮬레이터에 요구되는 것이 정확도뿐인 것은 아니다. 실리콘 브링업과 컴파일러 검증에는 골든 벡터, 곧 장치가 내놓아야 할 정수 텐서 그 자체가 필요하다. 학습 후 양자화 회귀를 추적하려면 어느 연산자에서 격차가 시작되었는지를 알아야 한다. 둘 다 텐서에 관한 질문이고, 저자가 아는 한 어느 쪽도 측정된 바 없다. 이 논문은 세 가지를 묻는다. **RQ1:** 정확도가 일치하면 텐서도 일치하는가? **RQ2:** 격차를 만드는 연산자는 무엇이며, 가장 큰 것을 없애면 격차가 닫히는가? **RQ3:** 정확도 대리지표는 무엇에 값을 매기지 못하는가?

이 질문들에 답하려면 기존 계층별 오차 분석이 제공하지 않는 분해가 필요하다. 연산자 자신의 정수 연산이 만드는 뭉(국소 불일치, 교사 강제로 분리)과 중단간 실행에서 살아

남는 뭉(전파 불일치)을 갈라내는 분해다. 전체 테스트셋에서 대응 표준오차와 함께 보고하는 이 분해가 이 논문의 방법론적 기여이고, 발견 1–6이 실험적 기여다.

2. 배경 및 관련 연구

모의 양자화 그래프는 텐서를 양자화 격자에 맞춰 반올림하고 자른 뒤 다시 부동소수점으로 돌아오므로, 모든 연산자가 여전히 float32로 돈다. 정수 프로그램은 대신 int8 코드를 끝까지 유지하고 Q31 승수와 시프트로 다시 스케일한다 [1], [3]. 따라서 두 프로그램은 의도에서는 일치하고 최하위 비트마다 어긋날 자유를 갖는다.

MQBench [5]는 학술 양자화와 배포 가능한 백엔드 사이의 격차를 측정하되 그것을 정확도로 보고한다. 양자화 백서들 [4], [2]은 모의 양자화를 정수 파이프라인의 시뮬레이션으로 다룬다. 배포 툴체인이 계층별 오차 분석은 양자화된 계층이 부동소수점 대응물에서 얼마나 떨어져 있는지를 잴다. 이 논문의 측정은 종류가 다르다. 시뮬레이터가 장치에서 실제로 일어나는 정수 실행에서 얼마나 떨어져 있는지를, 신호 대 잡음비가 아니라 코드 단위로 잴다. 정수만 쓰는 트랜스포머 추론은 정수 LayerNorm과 소프트맥스 커널을 이미 확립했다 [6], [7]. 그 연산자에 대한 기여는 커널이 아니라 커널과 시뮬레이터가 어긋나는 크기이고, 그것을 고치는 것만으로는 충분하지 않다는 증거다. 누산기 폭은 학습 시 제약으로 연구되어 왔다 [9]. 여기서 재는 축은 그 대신 재양자화 단계의 반올림, 즉 순수한 구현 선택이다.

3. 측정 방법

3.1 정수 엔진과 외부 검증

보정을 마친 모의 양자화 그래프를 정수 그래프로 내보낸다. int8 가중치, int32 편향, 출력 채널별 Q31 승수와 시프트로 이루어진다. 실행은 MultiplyByQuantizedMultiplier의 gemmlowp/TensorFlow Lite 의미론을 따르며 [3], 포화 반올림 배중 상위곱과 2의 거듭제곱 반올림 나눗셈을 포함한다. 서로 독립인 두 구현(NumPy와 C++)이 모든 중간 텐서에서 일치해야 하고, 파이썬을 쓰지 않는 세 번째 C++ 실행기가 직렬화된 파일로부터 같은 코드를 재현한다.

엔진은 자기 자신이 아니라 외부 오라클에 대해 검증한다. TensorFlow Lite 완전 정수 모델의 스케일·영점·가중치·편향으로 정수 그래프를 세우면, 합성곱과 풀링이 기존 방식의 이중 반올림을 쓰고 완전 연결 계층이 단일 반올림을 쓸 때 1000/1000 이미지의 모든 텐서에서 일치한다. 이 기준이 얼마나 뻣뻣한지에 대한 눈금으로, 같은 모델에서 TensorFlow Lite 자신의 최적화 델리게이트와 참조 커널은 1000장 중 155장에서 서로 다른 답을 낸다.

저자는 무소속 연구자이다. [도시], 대한민국. e-mail: ykh13571@gmail.com

표와 그림을 재현하는 데 필요한 코드·체크포인트·결과 파일 전부: <https://github.com/sokldjs554/npuloop>.

표 I

모의 양자화 대 비트 단위로 일치하는 정수 실행, 전체 테스트셋, PC는 채널별 가중치, PT는 텐서별 가중치, Δ는 같은 이미지에서 랜 (정수 - 모의) TOP-1이며 대응 표준오차를 함께 적었다. “코드”는 서로 다른 출력 로짓 코드의 비율, “이미지”는 코드가 하나라도 다른 이미지의 비율이다.

신경망	방식	float32	모의	정수	Δ (%p)	95% CI	일치(%)	코드(%)	이미지(%)
ResNet-20 ReLU	PC	89.59	89.54	89.55	+0.01 ± 0.08	[-0.14, +0.16]	99.37	50.1	99
ResNet-20 ReLU	PT	89.59	89.61	89.67	+0.06 ± 0.08	[-0.11, +0.23]	99.18	51.7	99
ResNet-20 SiLU	PC	90.34	90.35	90.26	-0.09 ± 0.09	[-0.26, +0.08]	99.06	61.6	100
ResNet-20 SiLU	PT	90.34	90.17	90.26	+0.09 ± 0.09	[-0.08, +0.26]	99.07	62.9	100
MobileNetV2-0.5	PC	90.23	90.30	90.29	-0.01 ± 0.08	[-0.16, +0.14]	99.28	50.4	100
MobileNetV2-0.5	PT	90.23	90.23	90.27	+0.04 ± 0.07	[-0.10, +0.18]	99.37	51.4	100
ViT-128/6	PC	80.98	80.87	80.97	+0.10 ± 0.13	[-0.15, +0.35]	97.93	72.7	100
ViT-128/6	PT	80.98	80.77	80.97	+0.20 ± 0.12	[-0.04, +0.44]	98.07	72.6	100
Inception-32	PC	89.59	89.55	89.56	+0.01 ± 0.05	[-0.09, +0.11]	99.69	28.5	95
Inception-32	PT	89.59	89.52	89.47	-0.05 ± 0.06	[-0.17, +0.07]	99.52	31.1	96
ResNet-20 (Imagenette)	PC	83.97	84.05	83.97	-0.08 ± 0.10	[-0.27, +0.12]	99.52	35.7	95
ResNet-20 (Imagenette)	PT	83.97	84.00	84.05	+0.05 ± 0.11	[-0.17, +0.27]	99.31	36.2	96

3.2 국소 불일치와 전파 불일치

한 장의 이미지에 대해, 모의 양자화 그래프가 노드 n 에서 만드는 코드를 f_n (양자화기 출력을 정수 코드로 환산한 것), 정수 엔진을 중단간으로 돌렸을 때 같은 노드에서 나오는 코드를 i_n 이라 하자. 노드 n 의 전파 불일치는 $f_n \neq i_n$ 인 원소의 비율이다. 국소 불일치는 노드 n 의 정수 커널에 입력으로 모의 양자화 코드를 먹이고(교사 강제) 그 노드의 출력만 비교한 것이다. 국소 불일치는 한 연산자의 정수 연산이 만드는 뭉을 떼어 내고, 전파 불일치는 그 뭉이 얼마나 멀리 가는지를 보여 준다.

3.3 통계, 모델, 양자화 방식

정확도 차이는 대응 표본으로 다룬다. 같은 이미지를 세 번(부동소수점, 모의 양자화, 정수) 평가하고, 이미지별 정답 여부 차이의 평균을 표준오차 $s/\sqrt{n}$ 및 95% Wald 구간과 함께 보고한다. 정확도 열은 전체 테스트셋을 쓴다(CIFAR-10 10,000장, Imagenette 3,925장). 노드별 분해는 고정된 250장 배치(Imagenette는 125장)를 쓴다.

CIFAR-10 신경망 5종 — ReLU를 쓰는 ResNet-20과 SiLU를 쓰는 ResNet-20, MobileNetV2-0.5(깊이별 합성곱), 분기를 연결하는 Inception 계열 CNN, ViT-128/6(어텐션 블록 12개, LayerNorm 13개) — 과 Imagenette를 128×128 로 쓰는 신경망 2종(ResNet-20과 4.2절의 초해상 신경망)을 쓴다. 학습 후 양자화 방식은 둘이다. 채널별 가중치에 비대칭 활성화를 쓰는 방식(PC)과 텐서별 가중치를 쓰는 방식(PT)이며, 둘 다 학습 이미지 512장으로 보정했다. 학습과 평가는 모두 CPU에서 수행했고, 아래의 모든 수치는 저장소에 커밋된 결과 파일에서 스크립트가 만들어 낸다.

4. 실험 결과

4.1 RQ1: 정확도는 일치하고 텐서는 일치하지 않는다

표 I이 핵심 측정이다. 모의 대 정수 정확도 차이의 최댓값은 0.20 %p, $|\Delta|/SE$ 의 최댓값은 1.6이며, 12개 신뢰구간이 모두 0을 포함한다. 이 표본 크기에서 정확도 대리지표는 정확한 것과 구별되지 않고, 이미지 단위 top-1 일치율은 97.9–99.7%다. 같은 행이 텐서에서는 어긋난다. 출력 로짓 코드의 28.5%(Inception-32)에서 72.7%(ViT-128/6)가 다르고, 이미지의 95–100%에서 코드가 최소 하나 다르다. 트랜스포머가 극단적이기는 하나 예외는 아니다. CNN들이 50–63%, 입력이 더 큰 Imagenette 모델이 36%에 자리한다.

표 II

출력 텐서가 결과물인 과제: IMAGENETTE에서의 ESPCN $\times 2$, 이미지 3,925장, 이미지당 출력값 49,152개를 같은 폭 구성의 두 깊이에서 측정했다. PSNR은 [0, 1] 범위의 dB. 양자화 자체는 FLOAT32 대비 합성곱 3개에서 0.28–0.67 dB, 9개에서 0.57–1.15 dB를 잃으며 이는 옆 칸의 모의-정수 차이보다 세 자릿수 크다. 반면 코드가 다른 비율은 깊이에 따라 한 자릿수 움직인다.

합성곱	방식	float32	모의	정수	Δ (10^{-3} dB)	코드(%)	max $ \Delta c $
3	PC	30.234	29.956	29.955	-0.64 ± 0.04	6.3	3
	PT	30.234	29.567	29.568	+0.27 ± 0.06	18.2	3
9	PC	30.113	29.544	29.543	-0.51 ± 0.18	69.2	10
	PT	30.113	28.966	28.968	+2.88 ± 0.19	73.0	10

발견 1. 정확도 일치와 텐서 일치는 두 자릿수 이상 분리되어 있으며, 모든 신경망과 두 방식 모두에서 그렇다.

실무 함의. 정확도가 99% 일치한다는 보고는 시뮬레이터가 검증 벡터를 공급할 수 있다는 증거가 되지 못한다.

4.2 RQ1: 텐서 자체가 결과물일 때

위의 신경망은 모두 분류기여서 출력 텐서와 답 사이에 argmax가 하나 서 있다. 그것을 건너내기 위해 부분 픽셀 초해상 신경망 [8]을 쓴다. Imagenette를 $64 \rightarrow 128$ 로 올리며, 최근접 이웃 확대의 27.26 dB에 대해 30.23 dB이고, 출력이 곧 그림 그 자체다. 새 연산자 지원은 필요 없었다. 픽셀 서플은 reshape와 transpose다. 깊이와 과제를 분리하기 위해 폭 구성을 고정한 두 깊이에서 랜다. 원래의 합성곱 3개, 그리고 본체 폭에 잔차 블록 3개를 넣은 합성곱 9개다. 깊은 쪽이 더 좋은 신경망인 것은 아니다(30.11 dB 대 30.23). 같은 과제를 연산자 수만 세 배로 늘려 본 것이다.

표 II는 같은 그림을 반복하면서 깊이에 숫자를 붙인다. 합성곱 3개에서 양자화 비용은 0.279 dB(PC)와 0.667 dB(PT)이고 시뮬레이터는 그 비용을 6×10^{-4} dB 안쪽으로 맞힌다. 이 표본 크기에서는 분해되는 차이지만($|\Delta|/SE = 17.6$) 맞히려는 비용보다 세 자릿수 작다. 그런데도 출력 픽셀 코드의 6.3%와 18.2%가 3,925장 전부에서 다르고, 최대 3레벨까지 벌어진다. 합성곱 9개에서는 품질 지표가 여전히 3×10^{-3} dB 안쪽으로 충실한데 코드가 다른 비율은 69.2%와 73.0%로, 최대 편차는 10레벨로 오른다. 연산자별 구조는 두 깊이 모두 CNN과 같다. 합성곱의 국소 불일치는 0.06–0.40% 이고 모두 최하위 비트 ± 1 이며, 첫 분기점도 첫 합성곱이다.

발견 2. 이 분리는 분류 과제의 인공물이 아니며, 전파 비율의 크기를 정하는 것은 과제가 아니라 깊이이다. 같은 이미지에 합




그림 1. 노드별 코드 불일치, PC 방식. 국소(교사 강제) 불일치는 LayerNorm을 빼면 모든 연산자에서 1% 미만이고, 전파 불일치는 첫 합성곱에서 시작해 출력의 50–73%까지 올라간다. 세로축은 로그 눈금이며, 국소 불일치가 0인 노드는 그리지 않았다 — 록업 테이블 활성화 전부와 잔차 덧셈 100개 중 95개가 여기 해당한다.

성곱 9개를 쓰면 6.3%가 69.2%로 올라 분류기들이 차지하는 28–73% 구간 안으로 들어오는데, 품질 지표는 그동안 내내 충실하다.

실무 함의. 시뮬레이터는 기준 로짓 벡터를 공급할 수 없듯이 기준 이미지도 공급할 수 없으며, 그래프가 깊을수록 내보내는 텐서 중 재현하는 몫은 줄어든다.

4.3 RQ2: 격차는 어디서 태어나는가

그림 1이 두 성분을 갈라 놓는다. 국소 불일치는 작고 평평하다. 합성곱은 자기 코드의 0.02–0.93%, 선형 계층은 0.03–0.96%, 평균 풀링은 0.1–2.7%(반올림 동점)에서 어긋나며, int8 록업 테이블 활성화는 정확히 0%다. 이들은 모두 최하위 비트 ± 1 차이이며, 이 연구에서 관측한 모든 국소 불일치가 — LayerNorm까지 포함해 — ± 1 이다. 반면 전파 불일치는 첫 합성곱에서부터 — 12개 행 전부에서 첫 격차가 그 노드다 — 단조롭게 올라가 출력에서 28–73%에 이른다.

작지 않은 연산자가 하나 있다. 정수 LayerNorm은 부동소수점 대응물과 자기 코드의 24.8%에서 어긋나며, 13개 인스턴스 중 최댓값은 26.2%다. 정수 구현은 int64 합과 정확한 정수 제공근으로 정규화하는 반면 시뮬레이터는 float32로 계산한 뒤 격자에 스냅하므로, 대략 원소 넷 중 하나가 반올림 경계의 반대편에 떨어진다.

발견 3. LayerNorm을 빼면 어떤 연산자도 자기 코드의 1% 미만에서만 어긋나고, 그 어긋남은 모두 최하위 비트 ± 1 이다. 종단간 격차는 특정 커널이 만든 것이 아니라 전파가 키운 것이다.

발견 4. 정수 LayerNorm은 유일하게 큰 국소 원천으로, 다른 모든 연산자보다 두 자릿수 크다.

실무 함의. 트랜스포머를 INT8로 옮길 때는 LayerNorm을 가장 먼저 의심하고, 나머지에서는 ± 1 LSB를 예상하라.

4.4 RQ2: 가장 큰 국소 원천을 제거하면

격차가 연산자별 오차의 합이라면 가장 큰 항을 없앴을 때 그만큼 줄어야 한다. 이를 직접 시험한다. 시뮬레이터의

표 III
시뮬레이터의 LAYERNorm을 정수에 충실하게 바꾼 결과(ViT-128/6, 10,000장). 각 방식의 두 행 사이에서 정수 프로그램은 바뀌지 않았고 시뮬레이터의 LAYERNorm만 다르다. 로짓 절대차 평균은 PC에서 0.119 → 0.091, PT에서 0.118 → 0.093으로 줄어든다.

방식	LayerNorm	국소(%)	코드(%)	일치(%)	Δ (%p)
PC	float32	24.77	72.7	97.93	$+0.10 \pm 0.13$
PC	정수 (13개)	0.00	65.7	98.29	$+0.25 \pm 0.11$
PT	float32	24.76	72.6	98.07	$+0.20 \pm 0.12$
PT	정수 (13개)	0.00	66.0	98.60	$+0.13 \pm 0.10$




그림 2. 기준 재양자화 반올림 대비 top-1 변화. 전체 테스트셋, 신경망당 독립적으로 학습한 체크포인트 3개(오차 막대는 대응 표준오차). 편향된 방식들은 모든 조합에서 손해를 보지만, 얼마나 손해인지는 시드마다 다르다.

표 IV
기준 구현 대비 반올림 방식의 손해, 시드 3개의 평균 $\pm$ 표준편차(%p).

반올림	ResNet-20 ReLU	ResNet-20 SiLU	MobileNetV2-0.5
single	-0.03 ± 0.09	$+0.01 \pm 0.02$	-0.00 ± 0.13
half_even	-0.07 ± 0.09	$+0.02 \pm 0.09$	$+0.00 \pm 0.09$
truncate	-0.98 ± 0.12	-2.31 ± 0.85	-2.12 ± 0.21
floor	-1.42 ± 0.06	-2.42 ± 1.04	-1.43 ± 0.40

LayerNorm을, 입력 코드 위에서 엔진의 연산을 그대로 수행하여 구성적으로 비트 단위까지 같은 모듈로 교체하되, 내보낸 정수 프로그램은 그대로 둔다(실험이 이 사실을 단언한다).

표 III이 그 결과다. LayerNorm의 국소 불일치는 24.77%에서 정확히 0.00%로 내려가고 로짓 절대차 평균은 약 23% 개선된다. 그러나 전파된 출력 코드 불일치는 72.7%에서 65.7%로만 움직인다(텐서별은 72.6% → 66.0%). 정확도는 어느 방향으로든 대응 표준오차 두 배 안쪽에서 움직이므로 개선으로 읽을 수 없다.

발견 5. 가장 큰 국소 원천 하나를 완전히 없애도 전파 격차의 10분의 1 정도만 회수된다. 남은 것이 개별적으로는 코드의 1% 미만에서만 어긋나는 연산자들의 ± 1 LSB 사건이 증폭된 결과이기 때문이다.

실무 함의. 골든 벡터는 외부 기준에 대해 검증된 정수 구현에서 나와야 한다. 부동소수점 시뮬레이터를 연산자 하나씩 고쳐 나가는 길은 대체제가 되기에 너무 느리게 수렴한다.

4.5 RQ3: 정확도 대리지표가 가리는 비용

재양자화의 곱셈-시프트는 반올림 단계로 끝나는데, 구현에 따라 이를 단순 산술 시프트로 바꾸고 싶은 유혹이 있다. 그림 2과 표 IV은 그 선택을 기준 구현과 비교해 전체 테스트

셋에서, 신경망당 독립적으로 학습한 체크포인트 3개로 측정 한 것이다.

truncate와 floor는 18개 (모델, 시드, 방식) 조합 전부에서 기준보다 나빴고, 그 폭은 0.90–3.37 %p, $|\Delta|/SE$ 는 4.4에서 11.8 사이였다. 반면 단일 반올림과 짝수 반올림 경로는 잡음 범위를 벗어나지 않는다($|\Delta| \leq 0.13$ %p). 크기는 옮겨 가지 않는다. ResNet-20 SiLU에서 truncate의 손해는 시드 3개에 걸쳐 1.36에서 2.98 %p까지 벌어져 시드 표준편차가 효과 크기의 37%에 이르는 반면, ResNet-20 ReLU는 효과의 10분의 1 이내에 머문다. 두 편향 방식 중 어느 쪽이 더 나쁜지는 연산의 성질이 아니라 신경망의 성질이다. ResNet-20 ReLU는 세 시드 모두에서 floor가, MobileNetV2는 세 시드 모두에서 truncate가 더 많이 옳는다.

발견 6. 반올림 방식 비용의 부호와 유의성은 시드에 강건하지만 크기는 그렇지 않다. 같은 구조의 시드 3개에서 효과 크기의 37%까지 벌어진다.

실무 함의. 반올림 방식의 비용을 시드 하나의 수치로 인용해서는 안 된다.

5. 타당성 위험

외적 타당성. 신경망은 CIFAR-10 규모에 128×128 ImageNet 모델 셋을 더한 것이고, 가장 깊은 것이 연산자 32개다. 따라서 결론은 격차의 구조에 관한 것이지만 ImageNet 규모 그래프에서의 정확한 크기에 관한 것이 아니다. 규모 축 가운데 직접 바뀌 본 것은 깊이 하나인데(4.2절) 그것만으로 전파 비율이 한 자릿수 움직인다. 그러므로 그 비율은 측정된 그래프의 성질로 읽어야 하며 INT8의 상수로 읽어서는 안 된다.

구성 타당성. 국소 불일치는 교사 강제로 재드로 연산자의 연산만 떼어 보고 상류 오차와의 상호작용은 보지 않는다. 그 상호작용을 담는 것은 전파 열이다.

결론 타당성. 표 I의 정확도 비교 12개와 표 III의 4개는 다중 비교 보정을 하지 않았다(16개 전체에서 $|\Delta|/SE$ 의 최댓값은 2.2). 시드 3개는 반올림 측면 덮고, 나머지 측정은 신경망당 체크포인트 하나를 쓴다.

내적 타당성. 외부 비트 일치 검증은 합성곱·풀링·완전 연결 계층을 덮고, 깊이별 합성곱·원소별 덧셈·소프트맥스는 덮지 않는다.

6. 재현 자료

모든 수치는 커밋된 결과 파일에서 스크립트가 출력하며, 스크립트와 결과 파일과 체크포인트를 만드는 학습 명령은 모두 공개되어 있다(데이터 없이 돌려 볼 수 있도록 체크포인트 2개는 저장소에 함께 들어 있다). make_tables.py가 표 I–IV을, make_figs.py가 그림 1–2을 다시 만든다. 지속적 통합 작업이 커밋마다 생성기를 다시 돌려, 커밋된 표가 결과 파일이 함의하는 표와 다르면 실패시킨다. 측정 자체는 e15_fidelity.py (표 I, 그림 1), e16_ln_emulation.py (표 III), e14_rounding_seeds.py (그림 2, 표 IV), e17_dense_output.py (표 II)에 있고, 외부 검증은 e11_tflite_crosscheck.py다. 시드를 쓴 측정에는 단서가 하나 붙는다. 이 체크포인트들을 만들 당시 학습기의 시드는 데이터 순서만 통제하고 가중치 초기화는 통제하지 못했으므로, 세 반복은 서로 독립인 표본이지만 같은 명령으로 비트 단위까지 재현되지는 않는다.

7. 결론

모의 양자화는 INT8 품질은 잘 맞고 INT8 텐서는 잘 못 맞는다. 분류기에서도, 출력이 곧 결과물인 신경망에서도 그렇고, 두 사실은 서로 독립이다. 격차를 옮기는 연산자는 하나가 아니다. 개별적으로는 코드의 1% 미만에서만 어긋나는 연산자들에서 최하위 비트 ± 1 사건으로 태어나 전파로 자라며, 그래서 가장 나쁜 국소 원천을 없애도 10분의 1밖에 회수되지 않는다. 골든 벡터가 필요한 팀은 외부 기준에 대해 검증된 정수 구현에서 그것을 만들어야 하고, 재양자화의 세부를 바꾸는 팀은 여러 시드에서 측정해야 한다. 그 효과의 크기는 — 부호와 달리 — 옮겨 가지 않기 때문이다.

감사의 글

저자는 이 원고의 준비 과정에서 AI 코딩 도구(Claude Code)를 사용했으며, 모든 내용에 대한 책임은 저자에게 있다.

참고문헌

- [1] B. Jacob *et al.*, “Quantization and training of neural networks for efficient integer-arithmetic-only inference,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 2704–2713.
- [2] R. Krishnamoorthi, “Quantizing deep convolutional networks for efficient inference: A whitepaper,” *arXiv:1806.08342*, 2018.
- [3] B. Jacob *et al.*, “gemmlowp: a small self-contained low-precision GEMM library,” 2017. [Online]. Available: <https://github.com/google/gemmlowp>
- [4] M. Nagel *et al.*, “A white paper on neural network quantization,” *arXiv:2106.08295*, 2021.
- [5] Y. Li *et al.*, “MQBench: Towards reproducible and deployable model quantization benchmark,” in *Proc. NeurIPS Datasets and Benchmarks Track*, 2021.
- [6] S. Kim *et al.*, “I-BERT: Integer-only BERT quantization,” in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2021, pp. 5506–5518.
- [7] Y. Lin *et al.*, “FQ-ViT: Post-training quantization for fully quantized vision transformer,” in *Proc. Int. Joint Conf. Artif. Intell. (IJCAI)*, 2022, pp. 1173–1179.
- [8] W. Shi *et al.*, “Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 1874–1883.
- [9] I. Colbert *et al.*, “A2Q: Accumulator-aware quantization with guaranteed overflow avoidance,” in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2023, pp. 16989–16998.

ENGLISH ABSTRACT

Per-Operator Attribution of the Fake-Quantization-to-Integer Gap in INT8 Inference

INT8 deployment decisions are made on a simulator: the network runs in floating point with quantize–dequantize (“fake-quantization”) nodes inserted, and its accuracy stands in for the integer target’s. Against an integer engine bit-exact with the TensorFlow Lite reference kernels, we measure how far that stand-in holds, for accuracy and for tensors separately. It holds for accuracy: over six networks, two schemes and complete test splits, every difference is within 0.20 pp and all twelve 95% intervals contain zero. It fails for tensors: 28.5–72.7% of the output codes differ, on 95–100% of the images. Teacher forcing attributes the divergence per operator, and repairing the simulator at its worst operator removes that source entirely (24.77% $\rightarrow$ 0.00%) while moving the propagated mismatch only to 65.7%. The decoupling survives the removal of the argmax, and depth sets the size of the propagated fraction: nine convolutions instead of three raise it from 6.3% to 69.2%, the quality metric faithful throughout.

Index Terms—Quantization, integer arithmetic, embedded inference, neural processing units, reproducibility.